

Avance 7. Resumen ejecutivo

Equipo 22 Maria Virginia Mendizabal Miranda - A01796588 Gianmel Joannelly Hernandez Tosta - A01795919 Sofia Ordaz Lopez - A01173717

Proyecto: Analisis de la contribucion de biomarcadores lipidomicos y metabolomicos en modelos de machine learning para cancer colorrectal. Fecha: Junio de 2026 Entregable: Avance7.Equipo22

1. Sintesis ejecutiva

El cancer colorrectal (CRC) es una de las principales causas de muerte por cancer a nivel mundial. La oportunidad clinica mas valiosa no consiste solo en identificar cancer confirmado, sino en detectar adenoma avanzado (AA), lesion precursora que puede removerse mediante colonoscopia antes de progresar a CRC. El proyecto evaluo si perfiles lipidomicos y metabolomicos fecales, combinados con variables clinicas, contienen senal suficiente para clasificar tres estados: control sano (CTRL), adenoma avanzado (AA) y cancer colorrectal (CRC).

La propuesta final es un modelo supervisado multiclase basado en Bagging Tree, entrenado sobre una matriz parsimoniosa de 16 variables: 12 biomarcadores lipidomicos y 4 variables clinicas/categoricas (age, fit_ug_g, gender_Male, fob_YES). El modelo alcanzo F1 macro de 0.855 en el conjunto held-out, AUC macro de 0.945 y F1 para AA de 0.78. Este resultado supera el baseline de Regresion Logistica (F1 macro = 0.628), el arbol individual (F1 held-out = 0.681), el antecedente multiclase PLS-DA reportado en el estudio original y los estudios comparativos revisados, donde AA vs control no se evalua o no se discrimina con claridad.

La recomendacion no es desplegar el sistema como diagnostico clinico autonomo. La recomendacion es implementar un piloto controlado de apoyo a investigacion y triage experimental, con validacion externa multicentrica, explicabilidad por paciente, monitoreo de drift y revision etica. Bajo supuestos conservadores, el piloto tiene costos directos estimados de MXN 665,000 para 12 meses de validacion y operacion inicial, con beneficios potenciales de MXN 1.0 a 2.6 millones anuales en eficiencia operativa si se aplica a 1,000 pacientes de tamizaje de alto riesgo, ademas de beneficios intangibles relevantes en prevencion, trazabilidad y aprendizaje clinico.

2. Sintesis del problema

El problema de negocio y salud publica es mejorar la deteccion temprana de lesiones colorrectales relevantes, especialmente AA. Las pruebas no invasivas actuales, como FIT/FOB, son utiles para tamizaje, pero presentan sensibilidad limitada para adenomas avanzados. En el dataset de referencia, el propio estudio de Albóniga et al. (2025) reporta que el modelo multiclase PLS-DA con FIT y esteres de colesterol no logra clasificar AA: la clase de mayor valor preventivo se colapsa.

El conjunto de datos utilizado contiene 211 observaciones de la cohorte del Hospital Universitario de Ourense, con tres grupos clinicos: CTRL = 78, AA = 58 y CRC = 75. Incluye variables clinicas y 127 lipidos medidos por UHPLC-MS. La pregunta central fue: puede un modelo de machine learning, con preprocesamiento riguroso y seleccion de biomarcadores, discriminar los tres estados de progresion de CRC mejor que los enfoques previos y sin depender exclusivamente de FIT?

El valor de resolver este problema es doble. En el plano clinico, detectar AA abre una ventana de prevencion antes del cancer invasivo. En el plano operativo, un modelo de triage podria priorizar colonoscopias, orientar paneles lipidomicos dirigidos y generar evidencia para estudios multicentricos posteriores.

3. Comentarios y analisis de papers comparativos

Por indicacion de la Dra. Grettel, Aldo Ibanez realizo una busqueda bibliografica en Scopus para ubicar articulos comparables al paper base. El material compartido incluye cuatro articulos originales de los ultimos ocho anos con enfoque similar: metabolomica/lipidomica en muestras fecales para distinguir CRC, adenoma/adenoma avanzado y controles sanos. La conclusion transversal del analisis comparativo es importante para este proyecto: los estudios respaldan el valor de metabolitos fecales para detectar CRC, pero ninguno resuelve de forma robusta la discriminacion AA vs controles sanos.

Articulo comparativo	Muestra	Metodos principales	Resultado clave	AA vs CTRL
Metabolomic analysis of gut metabolites in patients (Oncology Letters, 2023)	35 CRC, 37 CRA, 30 controles sanos	UHPLC-MS/MS, PCA, OPLS-DA, prueba de permutacion, analisis univariado, ROC y supervivencia global	Detecto 1641 metabolitos; reporto metabolitos asociados a CRC vs controles y CRA vs controles	No
A novel approach on the use of samples from faecal occult blood screening kits for metabolomics analysis (Metabolites, 2023)	Tres lotes: CTL, AD y CRC; total con predominio de CTL/AD y pocos CRC en lote 3	CV%, PCA, PLS-DA, OPLS-DA, ANOVA, t-test/Mann-Whitney	PLS-DA/OPLS-DA separaron visualmente, pero no pasaron criterios de validacion; diferencias significativas solo CTL vs CRC o AD vs CRC	No; CTL y AD no tuvieron diferencias suficientes
A comprehensive metabolomics analysis of fecal samples from advanced adenoma and colorectal cancer patients (Metabolites, 2022)	40 controles, 40 AA, 40 CRC	UHPLC-MS/MS, PCA, Random Forest, Regresion Logistica, k-fold CV y LOOCV	RF multiclase obtuvo 52% de exactitud; CTL y AA se confundieron con frecuencia; fusion CTL+AA vs CRC alcanzo 75%	No
Targeted UPLC-MS metabolic analysis of human faeces reveals novel low-invasive candidate markers for colorectal cancer (Cancers, 2018)	40 AA, 40 CRC, 49 controles	UPLC-MS, ANOVA, PCA, PLS-DA, Regresion Logistica y ROC	ChoE y FOB mejoraron la discriminacion de CRC; siete metabolitos mas FOB alcanzaron AUC mediana de 0.885	No

El benchmark externo refuerza tres comentarios ejecutivos. Primero, la metabolomica fecal es una via biologicamente plausible y metodologicamente consistente: los cuatro estudios usan espectrometria de masas y reportan senales en esfingolipidos, esterios de colesterol, trigliceridos, hemoglobina fecal u otros metabolitos. Segundo, la literatura converge en una dificultad especifica: AA tiende a parecerse mas a controles que a CRC, por lo que los enfoques no supervisados (PCA/PLS-DA) o las comparaciones binarias tienden a ocultar justamente la clase preventiva mas importante. Tercero, nuestro proyecto aporta una mejora diferencial porque formula el problema como clasificacion multiclase desde el inicio, reporta metricas por clase y logra F1 AA = 0.78 con Bagging Tree, en lugar de colapsar AA con controles o con CRC.

Estos papers tambien ayudan a interpretar los biomarcadores seleccionados. La aparicion repetida de familias como ChoE/CE, SM y TG en la literatura es coherente con variables relevantes de nuestro modelo, como CE(20:5), TG(51:4), SM(d18:0/18:0) y PC(O-16:0/16:0). Por tanto, el modelo no solo mejora el desempeno tecnico; tambien mantiene continuidad biologica con hallazgos previos.

4. Hallazgos principales del EDA

El analisis exploratorio confirmo que el dataset es pequeno pero informativo. La distribucion de clases tiene desbalance leve: CTRL 37.0%, CRC 35.5% y AA 27.5%, por lo que Macro F1 fue elegida como metrica principal para no ocultar el desempeno de AA.

La calidad de datos requirio decisiones explicitas. Se identificaron 27 lipidos con mas de 20% de valores faltantes y 5 con mas de 40%, que fueron eliminados. El mecanismo de ausencia no fue aleatorio: 13 de 56 lipidos evaluados tuvieron missingness dependiente del grupo (chi-cuadrada, $p < 0.05$). Este patron es compatible con concentraciones por debajo del limite de deteccion, mas frecuentes en controles para ciertos lipidos elevados en CRC. Por ello se eligio imputacion por mediana de grupo y se valido contra MICE. La mediana de grupo preservó mejor la estructura de correlacion (norma de Frobenius 3.24 vs 13.58).

Las distribuciones lipidomicas presentaban alta asimetria. Box-Cox fue la transformacion seleccionada porque redujo la mediana de skewness absoluta de aproximadamente 5.47 a 0.03. Despues de transformar, se detectaron 769 outliers sobre 25,742 celdas (2.99%), una tasa razonable para mediciones biologicas.

En el analisis multivariado, PCA mostro superposicion sustancial entre CTRL, AA y CRC, lo que indica que la senal no aparece en los ejes no supervisados de maxima varianza. En contraste, la seleccion supervisada si identifico biomarcadores discriminativos. fob_YES fue una variable categorica altamente informativa (chi-cuadrada = 23.9), mientras que entre las numericas destacaron lipidos como GlcCer(d18:1/24:0), CE(20:5), TG(51:4) y PC(O-16:0/16:0). Tambien se observo multicolinealidad relevante: la correlacion intra-familia fue aproximadamente cinco veces mayor que la inter-familia, por lo que la parsimonia de features se volvio una decision critica.

5. Modelos generados y eleccion del modelo final

La evolucion de modelos siguio la logica CRISP-ML(Q): baseline interpretable, modelo individual y ensamble. Primero se entreno Regresion Logistica multiclase sobre X_intersect, obteniendo F1 macro de 0.628, F1 para AA de 0.38 y recall AA de 0.47. Este baseline mostro viabilidad predictiva, pero tambien revelo que AA era la clase dificil.

Despues se evaluo un Decision Tree individual. El arbol mejoro el F1 macro a 0.707 en validacion cruzada y 0.681 en held-out, con recall AA cercano a 0.50. Este modelo apporto interpretabilidad, pero presento alta varianza e inestabilidad esperada en datasets pequenos.

Finalmente se evaluaron modelos ensamble. El modelo seleccionado fue Bagging Tree sobre X_intersect, con 100 arboles agregados por bootstrap. Fue elegido porque redujo la varianza del arbol individual, mantuvo interpretabilidad razonable mediante importancia de variables y obtuvo el mejor equilibrio entre desempeno, parsimonia y utilidad clinica. Sus resultados principales fueron:


Metrica	Resultado
F1 macro held-out	0.855
F1 macro CV	0.802
AUC ROC macro	0.945
F1 AA	0.78
Recall AA	0.75
Recall CRC	0.93
Precision CTRL	1.00
Numero de features	16

5.1 Visualizacion ejecutiva de hallazgos

La figura sintetiza el hallazgo mas importante para un tomador de decisiones: la clase AA, que es la ventana preventiva del proceso clinico, pasa de no estar resuelta en el benchmark multiclase previo a obtener desempeno util con el modelo final. En este grafico, la escala se interpreta como F1 para AA cuando esta disponible; para Top 15 se reporta el valor exploratorio observado en held-out.

Figura 1. Recuperacion de la clase preventiva AA

Comparacion de desempeno reportado o estimado por etapa/modelo



Lectura: la mejora clave no es solo global; es recuperar AA, la ventana de prevencion.

La eleccion de X_intersect se justifica porque concentra senal robusta bajo dos criterios independientes: Mutual Information y ANOVA. Tambien evita el riesgo de sobreajuste asociado con X_full (131 variables). Como analisis complementario, X_full Top 15 con Bagging Tree conservo Recall AA = 0.833 y F1 AA = 0.833, por lo que queda como candidato para validacion futura, pero no reemplaza al modelo final hasta completar nested CV y validacion externa.

6. Recomendaciones clave de implementacion

La implementacion debe realizarse como piloto controlado, no como herramienta diagnostica autonoma. El objetivo del piloto es validar integracion tecnica, estabilidad del pipeline y utilidad para priorizacion experimental.

Las acciones prioritarias son:

Recomendacion	Responsable	Entregable esperado	Prioridad
Validar el modelo con cohorte externa independiente, idealmente $n \geq 200$ y multicentrica	Patrocinador academico y equipo clinico	Reporte de metricas externas vs internas	Alta
Regularizar Bagging Tree ($\text{max_depth}=7-10$, $\text{m_in_samples_leaf}=3-5$)	Equipo de ciencia de datos	Modelo con brecha train-CV menor a 0.10	Alta
Generar explicabilidad SHAP por paciente	Equipo ML y equipo clinico	Reporte interpretativo por prediccion	Alta

Disenar panel lipidomico reducido basado en Top 15	Laboratorio de espectrometria y equipo ML	Lista de biomarcadores y protocolo MRM/SRM	Alta
Aprobar protocolo etico y consentimiento informado	Comite de etica	Protocolo aprobado	Alta
Implementar prototipo en Google Vertex AI	Equipo tecnico/MLOps	Endpoint, monitoreo y dashboard interno	Media-alta
Monitorear data drift, prediction drift y tasa de deteccion AA	Equipo MLOps	Alertas y reporte mensual	Alta

Google Vertex AI se recomienda como plataforma inicial por su continuidad con notebooks, pipelines reproducibles, Model Registry, monitoreo de drift y capacidad de escalar hacia validacion multicentrica. AWS SageMaker y Azure ML son alternativas viables si el hospital ya opera con esos ecosistemas.

7. Analisis costo-beneficio

7.1 Supuestos de planeacion

Las cifras siguientes son estimaciones para presentar a stakeholders y deben refinarse con cotizaciones institucionales. Se usa MXN como moneda de planeacion. Para servicios cloud internacionales se asume una paridad interna de referencia de 1 USD = MXN 18.50. El costo de hora tecnica se estima en MXN 350 para trabajo academico/prototipo. El costo de metabolomica no dirigida se estima en MXN 9,250 por muestra (aprox. USD 500) y el panel dirigido MRM/SRM en MXN 1,850 por muestra (aprox. USD 100), conforme a rangos comunes citados en el Avance 6.

7.2 Costos incurridos por fase CRISP-ML(Q)

Fase CRISP-ML(Q)	Concepto	Supuesto	Costo estimado
Business & Data Understanding	Adquisicion de datos y articulo base	Dataset y paper bajo acceso abierto/CC BY 4.0	MXN 0
Business & Data Understanding	Revision bibliografica y definicion del problema	24 h tecnicas	MXN 8,400
Data Preparation	Limpieza, reconstruccion de encabezados, imputacion, Box-Cox	60 h tecnicas	MXN 21,000
Data Preparation	Computo local y almacenamiento	Laptop existente, sin hardware dedicado	MXN 0
Modeling	Entrenamiento de baseline, arbol, ensembles y seleccion de features	45 h tecnicas	MXN 15,750
Evaluation	Validacion cruzada, held-out, analisis Top-K y metricas por clase	35 h tecnicas	MXN 12,250
Deployment planning	Arquitectura cloud, recomendaciones y documentacion	30 h tecnicas	MXN 10,500

Documentation	Integracion de avances y reporte ejecutivo	25 h tecnicas	MXN 8,750
Servidores/cloud usados hasta la fecha	Ejecucion local/notebooks; sin endpoint persistente	Costo incremental minimo	MXN 0
Software	Python, scikit-learn, pandas, Jupyter, Git	Open source	MXN 0
Total incurrido estimado		219 h tecnicas	MXN 76,650

7.3 Costos esperados de operacion y mantenimiento

Se plantea un piloto de 12 meses con 200 muestras externas para validacion y uso controlado sobre 1,000 predicciones de triage experimental.

Componente	Supuesto	Costo anual estimado
Panel lipidomico dirigido para validacion externa	200 muestras x MXN 1,850	MXN 370,000
Preparacion y control de calidad de datos externos	80 h tecnicas	MXN 28,000
Ajuste/regularizacion y nested CV	60 h tecnicas	MXN 21,000
SHAP, reporte clinico e interpretabilidad	50 h tecnicas	MXN 17,500
Cloud Vertex AI Workbench /Pipelines/Registry	MXN 3,500 mensuales	MXN 42,000
Endpoint online y batch prediction	MXN 2,800 mensuales	MXN 33,600
Monitoreo de drift y auditoria mensual	10 h/mes	MXN 42,000
Seguridad, documentacion etica y trazabilidad	60 h tecnicas	MXN 21,000
Mantenimiento correctivo/evolutivo	8 h/mes	MXN 33,600
Reserva de contingencia	10% del subtotal	MXN 56,970
Total operacion + validacion 12 meses		MXN 665,670

Si el modelo pasa a uso rutinario posterior al piloto, el costo recurrente sin validacion externa intensiva bajaria aproximadamente a MXN 150,000-220,000 anuales, mas el costo variable de muestras lipidomicas procesadas.

7.4 Beneficios cuantificables

Los beneficios se estiman para una cohorte anual de 1,000 pacientes en tamizaje de alto riesgo o derivados por sospecha clinica. No se asume que el modelo sustituya la colonoscopia; se asume que mejora priorizacion y reduce procedimientos innecesarios una vez validado.

Beneficio	Supuesto conservador	Valor anual estimado
Reduccion de colonoscopias innecesarias en controles	Evitar 10% de colonoscopias en pacientes de bajo riesgo; 70 procedimientos x MXN 8,000	MXN 560,000
Priorizacion temprana de AA	40 AA adicionales priorizados antes; ahorro operativo y clinico proxy de MXN 12,000 por caso	MXN 480,000
Sustitucion parcial de metabolomica no dirigida por panel dirigido	200 muestras: ahorro de MXN 7,400 por muestra	MXN 1,480,000

Reduccion de retrabajo analitico y revision manual	120 h clinico-tecnicas x MXN 500	MXN 60,000
Beneficio anual potencial bruto	Escenario con panel dirigido y triage validado	MXN 2,580,000

En un escenario prudente, aplicando solo 40% de captura efectiva por incertidumbre de adopcion, el beneficio anual seria MXN 1,032,000. Comparado con el costo anual del piloto (MXN 665,670), el retorno potencial seria positivo (beneficio/costo aproximado de 1.55). En un escenario completo, el beneficio/costo podria acercarse a 3.9. Estas cifras no deben interpretarse como ROI clinico definitivo, sino como racional economico para financiar la validacion.

7.5 Beneficios intangibles

El proyecto aporta beneficios cualitativos importantes. Primero, transforma mediciones lipidomicas complejas en una herramienta interpretable para investigacion clinica. Segundo, mejora la trazabilidad de decisiones mediante CRISP-ML(Q), versionamiento del pipeline y monitoreo. Tercero, permite generar hipotesis biologicas sobre biomarcadores como CE(20:5), TG(51:4) y PC(O-16:0/16:0). Cuarto, ayuda a construir capacidades institucionales de MLOps responsable en salud. Finalmente, enfoca la atencion en AA, clase que representa la ventana preventiva mas valiosa.

8. Riesgos y desafios de la solucion

La clasificacion de riesgos sigue cuatro categorias solicitadas en los recursos de la semana: datos, ataques, prueba y confianza, y cumplimiento.

Categoria	Riesgo	Impacto	Mitigacion
Datos	Cohorte unica de Ourense y n pequeno (211 muestras)	Sobreestimacion del desempeno y baja generalizacion	Validacion externa multicentrica con n >= 200 antes de uso clinico
Datos	Missingness MAR/MNAR por limite de deteccion	Sesgo si se imputa de forma global o se ignora la ausencia informativa	Mantener imputacion validada, indicadores de ausencia y auditoria por grupo
Datos	Drift por cambios en protocolo UHPLC-MS o poblacion	Degradacion silenciosa del modelo	Monitoreo de data drift y recalibracion documentada
Datos	Multicolinealidad lipidomica	Importancias inestables y explicaciones fragiles	Seleccion parsimoniosa, SHAP con cautela y validacion biologica
Ataques	Acceso no autorizado a datos de salud	Riesgo de privacidad y dano reputacional	Anonimizacion, IAM, cifrado, bitacoras y minimo privilegio
Ataques	Envenenamiento de datos en reentrenamiento	Modelo sesgado o inseguro	Reentrenamiento solo con cohortes aprobadas y revision de calidad
Ataques	Manipulacion de entrada o uso fuera de contexto	Predicciones no confiables	Validaciones de schema, rangos biologicos y alertas de anomalia

Prueba y confianza	Sobreaajuste del Bagging Tree (Train F1 = 1.00)	Desempeno menor en poblaciones nuevas	Regularizacion, nested CV y evaluacion externa
Prueba y confianza	Varianza del held-out pequeno (n = 43)	Confianza excesiva en F1 = 0.855	Reportar F1 CV = 0.802 como estimacion conservadora
Prueba y confianza	AA es biologicamente heterogeneo	Falsos negativos en la clase preventiva clave	Optimizar umbrales por clase y estudiar subtipos de AA
Prueba y confianza	Explicabilidad insuficiente para adopcion clinica	Baja confianza del usuario	SHAP por paciente y revision con especialistas
Cumplimiento	Uso como dispositivo medico sin validacion	Riesgo regulatorio y etico	Limitar el piloto a investigacion; no usar como diagnostico autonomo
Cumplimiento	Consentimiento y uso secundario de datos lipidomicos	Incumplimiento etico/legal	Protocolo aprobado por comite de etica y consentimiento explicito
Cumplimiento	Transferencia internacional o cloud de datos sensibles	Riesgo normativo	Datos anonimizados, region cloud definida, DPA/BAA si aplica
Cumplimiento	Sesgo por poblacion no representativa	Inequidad en desempeno	Reporte estratificado por sexo, edad, centro y subpoblacion

9. Cierre ejecutivo

El proyecto demuestra que existe senal lipidomica util para clasificar CTRL, AA y CRC, y que un ensemble de arboles con seleccion parsimoniosa de biomarcadores supera claramente los modelos previos evaluados. La contribucion central no es solo el F1 macro de 0.855, sino la recuperacion de desempeno en AA, clase que el antecedente multiclasa no lograba detectar.

La decision ejecutiva recomendada es financiar un piloto controlado de 12 meses. El costo estimado de MXN 665,670 es razonable frente a beneficios potenciales conservadores de MXN 1.0 millones anuales y frente al valor clinico de priorizar lesiones precancerosas. La condicion indispensable es mantener el sistema como apoyo experimental hasta completar validacion externa, explicabilidad, monitoreo, aprobacion etica y analisis de cumplimiento.

10. Referencias

Albóniga, O. E., Cubiella, J., Bujanda, L., Aspichueta, P., Blanco, M. E., Lanza, B., Alonso, C., & Falcón-Pérez, J. M. (2025). Metabolic signature in combination with fecal immunochemical test as a non-invasive tool for advanced colorectal neoplasia diagnosis. **Cancers**, 17(14), 2339. <https://doi.org/10.3390/cancers17142339>

Baccarin, F. (2020). Machine learning that pays the bills: choosing models in business contexts. **Towards Data Science**.

Babic, B., Cohen, I. G., Evgeniou, T., & Gerke, S. (2021). When machine learning goes off the rails. **Harvard Business Review**.

Breiman, L. (1996). Bagging predictors. **Machine Learning**, 24(2), 123-140.

Cubiella, J., Clos-Garcia, M., Alonso, C., Martinez-Arranz, I., Perez-Cormenzana, M., Barrenechea, Z., Berganza, J., Rodriguez-Llopis, I., D'Amato, M., Bujanda, L., Diaz-Ondina, M., & Falcon-Perez, J. M. (2018). Targeted UPLC-MS metabolic analysis of human faeces reveals novel low-invasive candidate markers for colorectal cancer. **Cancers**, 10(9), 300.

Metabolites. (2022). A comprehensive metabolomics analysis of fecal samples from advanced adenoma and colorectal cancer patients. **Metabolites**, 12(6), 550.

Metabolites. (2023). A novel approach on the use of samples from faecal occult blood screening kits for metabolomics analysis: application in colorectal cancer population. **Metabolites**, 13(3), 321.

Oncology Letters. (2023). Metabolomic analysis of gut metabolites in patients. **Oncology Letters**, 26(2).

Studer, S., Bui, T. B., Drescher, C., Hanuschkin, A., Winkler, L., Peters, S., & Müller, K. R. (2021). Towards CRISP-ML(Q): A machine learning process model with quality assurance methodology. **Machine Learning and Knowledge Extraction**, 3(2), 392-413.